

Die Rolle unbequemer Einwände bei der Stabilisierung wissenschaftlich haltbarer Ergebnisse

Eine experimentelle Untersuchung der funktionalen Bedeutung kritischer Gegenpositionen bei der Stabilisierung vorläufiger Forschungsergebnisse

Dr. Friedrich Unbedacht

Dr. Konrad P. Huber

Eingegangen: 10.12.2027 · S. 77–83

Zusammenfassung. Die vorliegende Untersuchung befasst sich mit der Frage, in welchem Umfang unbequeme Einwände zur wissenschaftlichen Belastbarkeit vorläufiger Ergebnisse beitragen und ab welchem Ausmaß ihre Berücksichtigung lediglich zu einer Verlängerung des Forschungsprozesses führt. Ausgangspunkt ist die Beobachtung, dass wissenschaftliche Ergebnisse häufig nicht deshalb als stabil gelten, weil keine Einwände mehr bestehen, sondern weil nach einer hinreichenden Zahl von Einwänden keine wesentliche Bereitschaft zur weiteren Veränderung des Ergebnisses erkennbar ist. In einer experimentellen Studie mit 36 Versuchspersonen wurden drei Bedingungen mit unterschiedlicher Einwandintensität untersucht. Die Teilnehmenden bewerteten jeweils identische Forschungsergebnisse, zu denen entweder keine Einwände, drei standardisierte Einwände oder zwölf aufeinanderfolgende Einwände vorgelegt wurden. Erfasst wurden wahrgenommene Ergebnisstabilität, Bereitschaft zur Revision, Bearbeitungsdauer und die Anzahl tatsächlich vorgenommener Änderungen. Die Ergebnisse zeigen, dass drei Einwände zu einer signifikanten Erhöhung der wahrgenommenen Belastbarkeit führten, während zwölf Einwände keinen zusätzlichen Anstieg der Stabilitätsbewertung bewirkten. Gleichzeitig nahm die Bearbeitungsdauer nahezu linear zu. Besonders bemerkenswert war, dass bei hoher Einwandintensität zwar häufiger über eine Revision nachgedacht, das ursprüngliche Ergebnis jedoch nicht häufiger verändert wurde. Die Befunde werden dahingehend interpretiert, dass wissenschaftliche Kritik eine doppelte Funktion besitzt: Sie erhöht zunächst die wahrgenommene Robustheit eines Ergebnisses, kann nach Überschreiten einer funktionalen Schwelle jedoch überwiegend zur Stabilisierung der bereits getroffenen Entscheidung beitragen. Daraus wird ein Modell der Einwandtoleranz abgeleitet, nach dem wissenschaftliche Ergebnisse weder durch die Abwesenheit von Kritik noch durch deren unbegrenzte Akkumulation, sondern durch eine begrenzte und strukturierte Einwandphase stabilisiert werden.

Schlüsselwörter: wissenschaftliche Kritik; Ergebnisstabilität; Einwandverhalten; Evidenzbewertung; Forschungsprozess

1. Einleitung

Wissenschaftliche Ergebnisse gelten im Allgemeinen dann als belastbar, wenn sie einer kritischen Prüfung standhalten. Kritik nimmt dabei eine zentrale Stellung innerhalb wissenschaftlicher Verfahren ein. Sie kann auf unzureichende Daten, alternative Erklärungen, methodische Schwächen oder auf die Möglichkeit hinweisen, dass ein beobachteter Zusammenhang lediglich zufällig entstanden ist. Entsprechend wird der Einwand häufig als notwendige Voraussetzung wissenschaftlicher Qualität betrachtet.

Gleichzeitig ist die praktische Funktion einzelner Einwände weniger eindeutig. Ein Ergebnis kann durch einen gut begründeten Einwand erheblich verbessert werden. Ein weiterer Einwand kann eine bereits bekannte Einschränkung lediglich wiederholen. Ein dritter Einwand kann eine alternative Interpretation eröffnen, die zwar logisch möglich, für die konkrete Fragestellung jedoch von geringer Bedeutung ist. Ab einem bestimmten Punkt stellt sich daher die Frage, ob zusätzliche Kritik noch zur Verbesserung eines Ergebnisses beiträgt oder lediglich dessen weitere Bearbeitung verlängert.

Diese Frage ist bislang insbesondere unter dem Gesichtspunkt der methodischen Qualität untersucht worden. Arbeiten zur kritischen Evidenzprüfung haben gezeigt, dass die Wahrnehmung wissenschaftlicher Belastbarkeit nicht ausschließlich von der Datenqualität abhängt, sondern auch davon, wie intensiv ein Ergebnis vor seiner abschließenden Darstellung geprüft wurde. [1] entwickelte hierfür den Begriff der *perzipierten Prüfungsdichte*, während [2] zeigte, dass bereits die bloße Dokumentation kritischer Rückfragen die spätere Einschätzung eines Forschungsergebnisses beeinflussen kann.

Eine verwandte Untersuchung von [3] deutete allerdings darauf hin, dass zusätzliche Einwände nicht zwangsläufig zu einer proportionalen Verbesserung wissenschaftlicher Entscheidungen führen. In einer Untersuchung von 18 Arbeitsgruppen nahm die Zahl der diskutierten Alternativ-erklärungen deutlich stärker zu als die Zahl tatsächlich vorgenommener Änderungen an den untersuchten Ergebnissen. Die Autoren interpretierten diesen Befund als Hinweis auf eine mögliche Diskrepanz zwischen kritischer Aktivität und tatsächlicher Ergebnisrevision.

Für die vorliegende Untersuchung ist insbesondere die Unterscheidung zwischen **Einwandwirkung** und **Einwandmenge** relevant. Ein Einwand kann eine Veränderung bewirken, weil er eine bislang übersehene Schwäche sichtbar macht. Eine größere Anzahl von Einwänden kann darüber hinaus signalisieren, dass ein Ergebnis intensiv geprüft wurde. Beide Mechanismen sind jedoch nicht identisch. Ein Ergebnis, das nach drei begründeten Einwänden unverändert bleibt, kann als stärker wahrgenommen werden als ein Ergebnis, das ohne Prüfung unverändert übernommen wurde. Ein Ergebnis, das nach zwölf weitgehend gleichartigen Einwänden weiterhin unverändert bleibt, muss dagegen nicht zwangsläufig stärker sein.

[4] beschrieb in einer konzeptionellen Untersuchung bereits die Möglichkeit einer sogenannten *kritischen Sättigung*. Darunter wurde ein Zustand verstanden, in dem zusätzliche Einwände zwar weiterhin registriert werden, aber keine wesentliche Veränderung der zugrunde liegenden Entscheidung mehr hervorrufen. Empirische Daten zu diesem Übergang lagen bislang jedoch nicht vor.

Die vorliegende Studie untersucht daher, wie sich unterschiedliche Mengen standardisierter Einwände auf die Wahrnehmung und Bearbeitung identischer wissenschaftlicher Ergebnisse auswirken.

1.1 Forschungsfrage

Die zentrale Forschungsfrage lautet:

Wie verändert sich die wahrgenommene wissenschaftliche Belastbarkeit eines Ergebnisses mit zunehmender Zahl kritischer Einwände, und ab welchem Punkt führen zusätzliche Einwände überwiegend zu einer Verlängerung des Prüfprozesses statt zu einer weiteren Ergebnisverbesserung?

Dabei wird zwischen drei Aspekten unterschieden:

1. der subjektiv wahrgenommenen Stabilität eines Ergebnisses,
2. der Bereitschaft, das Ergebnis zu revidieren,
3. dem tatsächlichen Bearbeitungsaufwand.

1.2 Hypothesen

Aus den theoretischen Überlegungen wurden vier Hypothesen abgeleitet.

H1: Die Präsentation mehrerer kritischer Einwände erhöht die wahrgenommene wissenschaftliche Belastbarkeit eines Ergebnisses gegenüber einer Bedingung ohne Einwände.

H2: Die wahrgenommene Belastbarkeit steigt nicht proportional mit der Zahl der Einwände, sondern erreicht nach einer begrenzten Anzahl kritischer Hinweise ein Plateau.

H3: Die Bearbeitungsdauer steigt mit zunehmender Einwandzahl stärker an als die Zahl tatsächlich vorgenommener Ergebnisänderungen.

H4: Eine hohe Einwandintensität erhöht die subjektive Bereitschaft zur Revision stärker als die tatsächliche Häufigkeit von Revisionen.

Die Hypothesen wurden vor Beginn der Datenerhebung festgelegt. Eine nachträgliche Anpassung der Schwelle für eine als „unbequem“ eingestufte Einwendung erfolgte nicht.

2. Methodik

2.1 Studiendesign

Die Untersuchung wurde als randomisiertes Between-Subjects-Experiment mit drei Einwandbedingungen durchgeführt. Alle Versuchspersonen erhielten dasselbe fiktive Forschungsergebnis. Dieses betraf einen Zusammenhang zwischen der wahrgenommenen Qualität einer alltäglichen Entscheidung und der Anzahl zuvor konsultierter Ratgeber.

Das Ausgangsergebnis lautete:

> Personen, die vor einer alltäglichen Entscheidung mindestens einen Ratgeber konsultieren, bewerten ihre Entscheidung nach Abschluss als sicherer als Personen, die keinen Ratgeber konsultieren.

Das Ergebnis wurde bewusst so formuliert, dass es weder offensichtlich falsch noch unmittelbar zwingend war. Dadurch sollte gewährleistet werden, dass die Versuchspersonen einen tatsächlichen Anlass zur Prüfung wahrnahmen.

Der experimentelle Unterschied bestand ausschließlich in der Anzahl der vorgelegten Einwände. In der Kontrollbedingung wurde kein Einwand präsentiert. In der mittleren Einwandbedingung wurden drei Einwände vorgelegt. In der hohen Einwandbedingung wurden zwölf Einwände vorgelegt.

Die Einwände wurden in allen Bedingungen in identischer Reihenfolge präsentiert, soweit sie Bestandteil der jeweiligen Bedingung waren. Jeder Einwand war auf einer separaten Seite dargestellt.

2.2 Stichprobe

An der Untersuchung nahmen 36 Personen teil. Die Stichprobe wurde aus dem erweiterten institutionellen Umfeld des Methodius-Instituts für angewandte Lebenswissenschaften gewonnen. Pro Bedingung wurden 12 Personen randomisiert zugewiesen.

Das mittlere Alter der Stichprobe betrug 41,3 Jahre (SD = 9,8). 19 Personen gaben an, regelmäßig wissenschaftliche Texte zu lesen, 17 Personen bezeichneten dies als gelegentlich. Eine gesonderte Prüfung des Zusammenhangs zwischen wissenschaftlicher Leseerfahrung und Reaktionsverhalten war nicht Gegenstand der primären Analyse.

Die Stichprobengröße wurde nicht anhand einer formalen Poweranalyse bestimmt. Ausschlaggebend war vielmehr die praktische Überlegung, dass für jede Bedingung eine zweistellige Zahl an Personen vorhanden sein sollte, damit ein einzelner besonders kritischer Einwand nicht unmittelbar die gesamte Bedingung dominieren konnte.

2.3 Operationalisierung der Einwandintensität

Die Einwände wurden anhand eines dreistufigen Kriterienrasters entwickelt.

Ein Einwand musste erstens einen erkennbaren Bezug zum vorgelegten Ergebnis besitzen. Zweitens durfte er keine Information enthalten, die das Ergebnis unmittelbar widerlegte. Drittens musste er eine theoretisch plausible alternative Betrachtung ermöglichen.

Die drei Einwände der mittleren Bedingung lauteten sinngemäß:

- Die Nutzung eines Ratgebers könnte bereits Ausdruck höherer Entscheidungssicherheit sein.
- Personen mit höherem Interesse an Entscheidungen könnten sowohl häufiger Ratgeber nutzen als auch ihre Entscheidungen positiver bewerten.
- Die Bewertung nach einer Entscheidung könnte stärker von der Erinnerung an die Entscheidung als von ihrer tatsächlichen Qualität beeinflusst werden.

Die zusätzlichen neun Einwände der hohen Bedingung bezogen sich unter anderem auf die Reihenfolge der Informationsaufnahme, die Länge des konsultierten Ratgebers, den Zeitpunkt der Befragung, die Möglichkeit selektiver Erinnerung und die Frage, ob eine Entscheidung überhaupt als abgeschlossen gelten könne, wenn nachträglich weitere Informationen verfügbar würden.

Damit wurde sichergestellt, dass die hohe Einwandbedingung nicht aus zwölf Wiederholungen desselben Arguments bestand. Gleichzeitig wurden die zusätzlichen Einwände so gewählt, dass sie das Ausgangsergebnis nicht grundsätzlich widerlegten.

2.4 Erhebungsinstrumente

Die wahrgenommene Ergebnisstabilität wurde mit einer eigens entwickelten siebenstufigen Skala erfasst. Die Versuchspersonen beantworteten nach Abschluss der Prüfung die Frage:

„Wie wissenschaftlich stabil erscheint Ihnen das vorgelegte Ergebnis nach der erfolgten Prüfung?“

Die Skala reichte von 1 („überhaupt nicht stabil“) bis 7 („außergewöhnlich stabil“).

Die Bereitschaft zur Revision wurde auf einer ebenfalls siebenstufigen Skala erfasst. Zusätzlich wurde dokumentiert, ob die Versuchsperson das ursprüngliche Ergebnis tatsächlich veränderte.

Als objektive Prozessvariable wurde die Zeit vom Beginn der ersten Einwanddarstellung bis zur abschließenden Entscheidung in Sekunden gemessen.

Zur Erfassung der wahrgenommenen Einwandrelevanz wurde außerdem nach jedem Einwand eine dichotome Entscheidung erhoben: „weiter prüfen“ oder „Ergebnis beibehalten“. Diese Variable diente vor allem der Analyse des Übergangs von aktiver Prüfung zu stabilisierender Bestätigung.

2.5 Statistische Auswertung

Für die primären Analysen wurden Mittelwerte und Standardabweichungen berechnet. Unterschiede zwischen den drei Bedingungen wurden mittels einfaktorieller Varianzanalyse untersucht. Zusätzlich wurden lineare Trendanalysen durchgeführt.

Da die Stichprobe klein war, wurden Effektstärken ergänzend zur Signifikanzbewertung angegeben. Für die Varianzanalyse wurde η^2 berichtet, für paarweise Unterschiede Cohen's d .

Die Schwelle für statistische Signifikanz wurde vorab auf $\alpha = 0,05$ festgelegt. Bei mehreren paarweisen Vergleichen wurde die Holm-Korrektur verwendet.

Die Auswertung erfolgte ausschließlich auf Basis der vorab definierten Variablen. Nachträgliche Einteilung einzelner Versuchspersonen als „besonders kritisch“ wurde nicht vorgenommen.

3. Ergebnisse

3.1 Wahrgenommene Ergebnisstabilität

Die wahrgenommene Stabilität des Ausgangsergebnisses unterschied sich zwischen den drei Bedingungen signifikant, $F(2, 33) = 6,84, p = 0,003, \eta^2 = 0,293$.

In der Bedingung ohne Einwände betrug der Mittelwert 4,42 (SD = 0,90). Nach drei Einwänden stieg die Stabilitätsbewertung auf 5,67 (SD = 0,78). Bei zwölf Einwänden lag sie mit 5,75 (SD = 0,87) nur geringfügig höher.

Damit zeigte sich insbesondere zwischen der Kontrollbedingung und der mittleren Einwandbedingung ein deutlicher Unterschied. Zwischen drei und zwölf Einwänden war dagegen praktisch kein weiterer Anstieg zu beobachten.

Die zentralen Kennzahlen sind in Tabelle 1 zusammengefasst.

Tabelle 1: Wahrgenommene Ergebnisstabilität, Revisionsbereitschaft und Bearbeitungszeit nach Einwandbedingung

Bedingung	n	Stabilität M	SD	Revisionsbereitschaft M	Bearbeitungszeit M (s)
Keine Einwände	12	4,42	0,90	2,83	94
Drei Einwände	12	5,67	0,78	4,08	173
Zwölf Einwände	12	5,75	0,87	5,17	491

Der Anstieg von 4,42 auf 5,67 Punkten zwischen der Kontroll- und der Drei-Einwände-Bedingung entsprach einer Effektstärke von $d = 1,47$. Der Unterschied zwischen drei und zwölf Einwänden betrug dagegen lediglich $d = 0,10$.

Damit wird H1 unterstützt, während H2 ebenfalls mit den Daten vereinbar ist. Die Stabilitätsbewertung erhöhte sich nach Einführung einer begrenzten Zahl kritischer Einwände deutlich, zeigte anschließend jedoch eine ausgeprägte Sättigung.

3.2 Bearbeitungsdauer und tatsächliche Revisionen

Die Bearbeitungszeit nahm dagegen deutlich stärker zu. Von durchschnittlich 94 Sekunden ohne Einwände stieg sie auf 173 Sekunden bei drei Einwänden und auf 491 Sekunden bei zwölf Einwänden.

Die Beziehung zwischen Einwandzahl und Bearbeitungszeit war annähernd linear. Eine lineare Regression ergab einen Anstieg von 32,8 Sekunden pro zusätzlicher Einwand

($R^2 = 0,91$). Da zwischen den experimentellen Bedingungen allerdings keine beliebigen Einwandzahlen, sondern nur drei festgelegte Stufen untersucht wurden, ist dieser Koeffizient ausschließlich als deskriptive Modellierung zu verstehen.

Abbildung 1 zeigt die beobachtete Bearbeitungsdauer.




Abbildung 1: Mittlere Bearbeitungsdauer in Abhängigkeit von der Zahl kritischer Einwände

Die tatsächliche Veränderung des Ergebnisses blieb hingegen selten. In der Kontrollbedingung änderten zwei Personen ihre ursprüngliche Bewertung. In der Drei-Einwände-Bedingung nahmen drei Personen eine Veränderung vor. In der Zwölf-Einwände-Bedingung änderten vier Personen das Ergebnis.

Der Anstieg von 16,7 % auf 25,0 % war damit deutlich geringer als der Anstieg der Bearbeitungszeit. Die hohe Einwandintensität führte folglich zu einer stärkeren Beschäftigung mit der Frage, ob das Ergebnis verändert werden sollte, ohne in vergleichbarem Umfang tatsächlich Veränderungen hervorzurufen.

3.3 Übergang zur kritischen Sättigung

Besonders aufschlussreich war die Entwicklung der Revisionsbereitschaft. Diese stieg von 2,83 Punkten in der Kontrollbedingung über 4,08 Punkte bei drei Einwänden auf 5,17 Punkte bei zwölf Einwänden.

Damit zeigte sich eine zunehmende Bereitschaft, die eigene Position erneut zu prüfen. Dieser Anstieg ging jedoch nicht mit einem entsprechenden Anstieg tatsächlicher Revisionen einher.

Der Unterschied zwischen subjektiver Revisionsbereitschaft und beobachteter Revision kann als Hinweis auf eine funktionale Trennung von **Prüfungsbereitschaft** und **Entscheidungsänderung** interpretiert werden. Die Versuchspersonen waren bei hoher Einwandintensität zunehmend bereit, die Möglichkeit einer Änderung zu erwägen, führten diese Änderung jedoch nur selten aus.

Die Befunde sind in Abbildung 2 dargestellt.

3.4 Prüfung der Hypothesen

Die Ergebnisse liefern Unterstützung für alle vier Hypothesen, allerdings mit unterschiedlicher Stärke.

H1 wurde durch den deutlichen Unterschied zwischen der Kontrollbedingung und den beiden Einwandbedingungen unterstützt. H2 wurde durch die nahezu identischen Stabilitätswerte bei drei und zwölf Einwänden bestätigt. H3




Abbildung 2: Stabilitätsbewertung und Revisionsbereitschaft nach Einwandintensität

wurde durch den starken Anstieg der Bearbeitungsdauer bei nur moderatem Anstieg der tatsächlichen Revisionen unterstützt. H4 wurde ebenfalls unterstützt, da die Revisionsbereitschaft deutlich stärker anstieg als die tatsächliche Revisionshäufigkeit.

Insgesamt ergibt sich somit ein konsistentes Muster: **Einwände erhöhen zunächst die wahrgenommene wissenschaftliche Belastbarkeit, anschließend jedoch vor allem den Aufwand, mit dem diese Belastbarkeit erneut bestätigt wird.**

4. Diskussion

4.1 Interpretation

Die zentrale Beobachtung der Studie besteht darin, dass Kritik offenbar nicht unbegrenzt zur Verbesserung eines wissenschaftlichen Ergebnisses beiträgt. Bereits drei strukturierte Einwände führten zu einem deutlichen Anstieg der wahrgenommenen Ergebnisstabilität. Eine Verfünfachung der Einwandzahl erzeugte anschließend kaum noch zusätzliche Stabilitätsgewinne.

Dieser Befund steht im Einklang mit dem Konzept der kritischen Sättigung von [4]. Dort wurde theoretisch angenommen, dass die Funktion eines Einwands davon abhängt, ob er eine neue Information in den Prüfprozess einführt. Sobald wesentliche Schwachstellen bereits adressiert wurden, können weitere Einwände zwar formal neue Aspekte enthalten, ohne die Entscheidungsgrundlage substantiell zu verändern.

Bemerkenswert ist dabei, dass die hohe Einwandintensität keineswegs folgenlos blieb. Die Versuchspersonen verbrachten wesentlich mehr Zeit mit dem Ergebnis und berichteten eine deutlich höhere Bereitschaft zur Revision. Dies könnte zunächst als Zeichen einer besonders gründlichen wissenschaftlichen Prüfung interpretiert werden. Gleichzeitig zeigen die tatsächlichen Revisionszahlen, dass die zusätzliche Prüfungsaktivität nur selten zu einer Änderung des Ergebnisses führte.

Ein vergleichbares Muster wurde bereits von [3] beschrieben. Dort zeigte sich, dass Arbeitsgruppen mit besonders langer Diskussionsdauer nicht zwangsläufig häufiger zu einer veränderten Schlussfolgerung gelangten. Die vorliegende Untersuchung ergänzt diesen Befund um die Beobach-

tung, dass sich der zusätzliche Aufwand subjektiv durchaus als wissenschaftlich relevant anfühlen kann, selbst wenn die Entscheidung am Ende unverändert bleibt.

Damit gewinnt die Unterscheidung zwischen **kritischer Prüfung** und **kritischer Beschäftigung** an Bedeutung. Erstere bezeichnet einen Prozess, durch den ein Ergebnis tatsächlich einer potenziell verändernden Prüfung unterzogen wird. Letztere bezeichnet dagegen einen Zustand, in dem weitere Einwände aufgenommen und bearbeitet werden, ohne dass ihre zusätzliche Informationsleistung noch hinreichend groß ist.

4.2 Die funktionale Einwandgrenze

Aus den vorliegenden Daten lässt sich eine einfache Modellvorstellung ableiten. Die wissenschaftliche Stabilität eines Ergebnisses steigt zunächst mit der Zahl relevanter Einwände. Dieser Anstieg flacht jedoch ab, sobald die wesentlichen Alternativverklärungen behandelt wurden.

Formal lässt sich dies als Sättigungsfunktion beschreiben:

$$S(n) = S + \alpha(1 - e^{-\beta n})$$

wobei $S(n)$ die wahrgenommene Stabilität nach n Einwänden bezeichnet, S die Ausgangsstabilität und α den maximal erwarteten zusätzlichen Stabilitätsgewinn.

Die vorliegenden Daten wurden nicht genutzt, um α und β mit ausreichender Präzision zu schätzen. Die Funktion dient vielmehr dazu, das beobachtete Verhältnis zwischen Einwandzahl und Stabilitätsbewertung konzeptionell zu beschreiben.

Demgegenüber kann der Bearbeitungsaufwand näherungsweise als lineare Funktion betrachtet werden:

$$T(n) = T + \gamma n$$

Für die vorliegende Stichprobe ergab sich deskriptiv $\gamma = 32,8$ Sekunden pro Einwand. Dies bedeutet nicht, dass jeder zusätzliche Einwand unter allen Bedingungen exakt 32,8 Sekunden benötigt. Es verdeutlicht jedoch den grundlegenden Unterschied zwischen beiden Funktionen: Während der Nutzen zusätzlicher Einwände abnimmt, bleibt ihr zeitlicher Aufwand bestehen.

Aus dieser Kombination entsteht eine praktische Schwelle. Unterhalb dieser Schwelle ist ein Einwand potenziell ergebnisverändernd. Oberhalb der Schwelle dient er zunehmend dazu, zu dokumentieren, dass auch dieser Einwand geprüft wurde.

4.3 Wissenschaftliche Stabilität als Prozessprodukt

Die Ergebnisse legen außerdem nahe, dass wissenschaftliche Stabilität nicht ausschließlich als Eigenschaft eines Ergebnisses verstanden werden sollte. Sie kann auch als Ergebnis eines sozialen und methodischen Prüfprozesses betrachtet werden.

Ein Ergebnis ohne Einwände kann sachlich korrekt sein, besitzt jedoch eine geringere dokumentierte Prüfungstiefe. Ein Ergebnis mit mehreren Einwänden verfügt dagegen über eine sichtbare Prüfungsgeschichte. Diese Prüfungsgeschichte kann wiederum dazu führen, dass das Ergebnis als belastbarer wahrgenommen wird, selbst wenn die Einwände keine Veränderung bewirkt haben.

Dieser Mechanismus entspricht der von [1] beschriebenen Prüfungsdichte. Dort wurde argumentiert, dass die Wahrnehmung wissenschaftlicher Sicherheit teilweise aus der Anzahl und Sichtbarkeit dokumentierter Prüfhandlungen entsteht. Die vorliegenden Daten zeigen, dass dieser Mechanismus nicht unbegrenzt skaliert.

Ein Ergebnis, das zwölf Einwände überstanden hat, wurde von den Versuchspersonen nicht wesentlich stabiler bewertet als ein Ergebnis, das drei Einwände überstanden hatte. Der zusätzliche Prüfaufwand war daher wesentlich größer als der zusätzliche wahrgenommene Erkenntnisgewinn.

4.4 Einwände als Stabilisierungselement

Eine besonders relevante Beobachtung besteht darin, dass Einwände nicht nur destabilisieren. Im wissenschaftlichen Alltag wird Kritik häufig als Gegenkraft zur Stabilisierung eines Ergebnisses verstanden. Die Daten legen jedoch nahe, dass Kritik nach erfolgter Prüfung auch stabilisierend wirken kann.

Ein Ergebnis, das einen relevanten Einwand übersteht, erscheint belastbarer als zuvor. Dieser Effekt kann sich wiederholen, solange neue Einwände tatsächlich neue Prüfungsdimensionen eröffnen. Sobald dies nicht mehr der Fall ist, kann der Prozess in einen Zustand übergehen, in dem die Einwände weniger das Ergebnis als die Rechtfertigung seiner Beibehaltung betreffen.

[2] bezeichnete diesen Prozess als *nachträgliche Evidenzverdichtung*. Der Begriff beschreibt den Umstand, dass die Dokumentation bereits erfolgter Prüfung selbst zu einem Bestandteil der späteren Beurteilung eines Ergebnisses werden kann.

Die vorliegenden Daten stützen diese Interpretation. Besonders die hohe Einwandbedingung zeigte eine deutliche Zunahme der Revisionsbereitschaft, ohne dass sich die tatsächlichen Entscheidungen entsprechend veränderten. Die Versuchspersonen prüften also länger, änderten aber nicht proportional häufiger.

4.5 Die Rolle unbequemer Einwände

Der Titel der vorliegenden Untersuchung bezieht sich nicht auf Einwände im Allgemeinen, sondern auf **unbequeme Einwände**. Damit sind solche Einwände gemeint, die eine Prüfung tatsächlich erforderlich machen, ohne bereits eine Entscheidung über das Ergebnis vorzugeben.

Ein Einwand verliert einen Teil seiner wissenschaftlichen Funktion, wenn er lediglich Zustimmung in anderer Form erzeugt. Ebenso problematisch wäre ein Einwand, der aufgrund seiner offensichtlichen Schwäche ohne weitere Prüfung verworfen werden kann.

Unbequem ist ein Einwand vielmehr dann, wenn er eine plausible Möglichkeit eröffnet, dass das bisherige Ergebnis geändert werden müsste.

In diesem Sinne kann die Qualität wissenschaftlicher Kritik nicht anhand ihrer Schwierigkeit oder Anzahl bestimmt werden. Entscheidend ist ihre **Informationsproduktivität**. Ein einzelner informationsproduktiver Einwand kann eine größere wissenschaftliche Funktion besitzen als zehn Einwände, die lediglich bereits geprüfte Gesichtspunkte neu formulieren.

Diese Überlegung steht in einem gewissen Spannungsverhältnis zu der von [2] beschriebenen Bedeutung der Prüfungsdokumentation. Während eine ausführliche Dokumentation Vertrauen erzeugen kann, darf ihre bloße Länge nicht mit ihrer inhaltlichen Produktivität verwechselt werden.

5. Limitationen

Die Studie weist mehrere Einschränkungen auf.

Erstens war die Stichprobe mit 36 Personen klein. Die beobachteten Effekte sollten daher nicht ohne weitere Untersuchung auf größere wissenschaftliche Arbeitsgruppen übertragen werden.

Zweitens wurde ausschließlich ein einzelnes fiktives Forschungsergebnis verwendet. Es ist möglich, dass die Wirkung von Einwänden davon abhängt, wie komplex, kontrolliert oder persönlich relevant ein Ergebnis ist.

Drittens wurde die Einwandintensität über die Anzahl der Einwände operationalisiert. Dadurch können Anzahl und kumulative Informationsmenge nicht vollständig voneinander getrennt werden. Zwölf Einwände erzeugen zwangsläufig mehr Text als drei Einwände.

Viertens wurden die Versuchspersonen über einen relativ kurzen Zeitraum untersucht. Eine tatsächliche wissenschaftliche Auseinandersetzung kann sich über Wochen oder Monate erstrecken. Insbesondere ist unklar, ob die beobachtete Sättigung nach längeren Pausen zwischen den Einwänden bestehen bleibt.

Fünftens wurde die tatsächliche Revision nur dichotom erfasst. Eine Veränderung des Ergebnisses wurde unabhängig davon als Revision gezählt, ob lediglich eine Formulierung geändert oder eine zentrale Schlussfolgerung verworfen wurde.

Diese Einschränkungen betreffen jedoch überwiegend die Generalisierbarkeit und nicht das grundsätzliche Muster der Ergebnisse. Zukünftige Studien sollten insbesondere untersuchen, ob die beobachtete Sättigung auch dann auftritt, wenn Einwände zeitlich verzögert oder durch unterschiedliche Personen vorgetragen werden.

Eine solche Untersuchung wäre insbesondere deshalb relevant, weil [1] und [4] unterschiedliche Annahmen darüber nahelegen, ob Prüfungsintensität primär durch die Anzahl der Einwände oder durch deren wahrgenommene Neuartigkeit bestimmt wird.

6. Weiterführende Forschung

Aus den Ergebnissen ergeben sich mehrere Ansätze für zukünftige Untersuchungen.

Eine erste Forschungsrichtung betrifft die **Einwandqualität**. In der vorliegenden Studie wurde die Zahl der Einwände variiert. Künftige Untersuchungen könnten dagegen dieselbe Anzahl von Einwänden mit unterschiedlicher Informationsproduktivität vergleichen.

Eine zweite Forschungsrichtung betrifft die **zeitliche Verteilung**. Es wäre zu prüfen, ob zwölf Einwände, die innerhalb weniger Minuten präsentiert werden, dieselbe Wirkung besitzen wie zwölf Einwände, die über zwölf Arbeitstage verteilt auftreten.

Drittens sollte untersucht werden, ob die Wirkung von Einwänden von der institutionellen Rolle der Person abhängt, die sie vorträgt. Ein identischer Einwand könnte möglicherweise anders verarbeitet werden, wenn er von einer Kollegin, einem Gutachter oder einer Person vorgebracht wird, die bereits zuvor als besonders kritisch wahrgenommen wurde.

Viertens wäre zu prüfen, ob wissenschaftliche Teams eine individuelle oder institutionelle Einwandtoleranz entwickeln. Eine Arbeitsgruppe könnte beispielsweise nach wiederholten Prüfungen eine höhere Zahl von Einwänden benötigen, bevor sie ein Ergebnis als stabil betrachtet.

Schließlich wäre eine Replikation mit realen wissenschaftlichen Texten sinnvoll. Dabei sollte insbesondere untersucht werden, ob die in der vorliegenden Studie beobachtete Diskrepanz zwischen Revisionsbereitschaft und tatsächlicher Revision auch bei Ergebnissen mit praktischer Konsequenz auftritt.

7. Fazit

Die vorliegende Untersuchung zeigt, dass kritische Einwände eine differenzierte Funktion im wissenschaftlichen Prüfprozess besitzen. Eine begrenzte Zahl relevanter Einwände erhöht die wahrgenommene Stabilität eines Ergebnisses deutlich. Zusätzliche Einwände führen anschließend jedoch nur noch zu einem geringen weiteren Anstieg der Stabilitätsbewertung, während der zeitliche Prüfaufwand weiter zunimmt.

Besonders hervorzuheben ist die Diskrepanz zwischen Revisionsbereitschaft und tatsächlicher Revision. Mit zunehmender Einwandintensität waren die Versuchspersonen zunehmend bereit, das ursprüngliche Ergebnis erneut infrage zu stellen. Dennoch änderten sie ihre Schlussfolgerung nur selten. Die zusätzliche Kritik führte damit überwiegend zu einer intensiveren Prüfung des bereits bestehenden Ergebnisses.

Die Ergebnisse sprechen für ein Verständnis wissenschaftlicher Kritik, bei dem nicht die maximale Zahl vorgebrachter Einwände, sondern deren Fähigkeit zur tatsächlichen Informationsveränderung entscheidend ist. Ein unbequemer Einwand erfüllt seine wissenschaftliche Funktion dann, wenn er eine relevante Entscheidung erzwingt oder eine relevante Möglichkeit zur Veränderung eröffnet. Sobald diese Funktion erfüllt ist, kann die weitere Akkumulation von Einwänden zwar die Dokumentation der Prüfung erweitern, ohne die wissenschaftliche Belastbarkeit im gleichen Maß zu erhöhen.

Für die wissenschaftliche Praxis ergibt sich daraus kein Argument gegen Kritik. Vielmehr sprechen die Befunde für eine strukturierte Einwandkultur, in der zwischen neuen Prüfungsinformationen und wiederholter Prüfungsaktivität unterschieden wird.

Ein Ergebnis muss demnach nicht deshalb als besonders belastbar gelten, weil es besonders viele Einwände überstanden hat. Entscheidend ist, ob die Einwände, die es hätte verändern können, tatsächlich vorgebracht und geprüft wurden.

Literatur

- [1] Schranke, T. (2022). Prüfungsdichte und die Wahrnehmung wissenschaftlicher Belastbarkeit. *Zeitschrift für Methodische Evidenz*, 9(2), 112–129.
- [2] Meissner, L. (2023). Nachträgliche Evidenzverdichtung in wissenschaftlichen Entscheidungsprozessen. *Archiv für Wissenschaftliche Urteilsbildung*, 11(4), 201–219.
- [3] Rothweiler, M., & Kappel, S. (2021). Diskussionstiefe und Ergebnisstabilität in kleinen Forschungskollektiven. *Beiträge zur Empirischen Wissenschaftsforschung*, 6(3), 44–63.
- [4] Unbedacht, F. (2024). Kritische Sättigung: Ein konzeptionelles Modell der begrenzten Einwandwirksamkeit. *Kritik & Evidenz*, 4(1), 17–36.
- [5] Huber, K. P., & Grau, E. (2020). Zwischen Prüfung und Bestätigung: Zur Funktion wiederholter Gegenargumente. *Journal für Angewandte Evidenz*, 8(2), 71–89.
- [6] Falkenberg, J. (2025). Informationsproduktivität kritischer Einwände bei der Bewertung vorläufiger Befunde. *Methodische Studien zur Alltagswissenschaft*, 13(1), 55–78.
- [7] Wieden, P. (2023). Die soziale Stabilisierung wissenschaftlicher Ergebnisse durch dokumentierte Gegenprüfung. *Zeitschrift für Wissenschaftspraxis und Entscheidungsforschung*, 10(3), 143–166.